Menduner

苏州城市活动情报平台

为酒店收益管理者提供可追溯的城市活动与外部需求信号

每一条数据都能回溯到原始网页，不确定的一律交人工审核

项目组 · 第 14 组

ENT303TC · 苏州 · 2026

系统已上线运行

http://47.116.133.230

问题

酒店定价看的是未来，但未来是看不见的

城市里的一次展会、一场演唱会，会在几天内把周边酒店的需求推高。这些活动信息其实是公开的，但散落在几十个网站，格式各异，真假混杂。

- **收益管理者每天要回答的问题**
  下周这个区域会不会突然住满？该提前锁价还是放量？
- **现在的做法**
  靠经验、靠零散微信推文、靠销售打电话问。信息滞后，无法追溯，无法量化。
- **根本障碍不是拿不到数据**
  而是不敢用一个来路不明的数字去改价格。

问题

为什么直接爬下来不能用

- **来源质量差一个量级**
  官方政府公告、场馆官网、聚合平台、社区用户帖，可信度完全不同。
- **同一活动有多个版本**
  标题标点不同、场馆叫法不同，同一场音乐会在两个来源里就是两条记录。
- **字段经常缺失**
  只有日期没有场馆、只有标题没有时间。静默丢弃会丢真实活动，静默补全就是编造。
- **聚合平台的时间可能只是概览**
  列表页上的 7 月 20 日 可能只是月份的展示，不是活动日期。

所以 Menduner 的目标不是爬到更多数据，而是让每一个进入系统的数字都经得起追问。

方案

三层结构：来源、证据、人工核验

01 • 来源

有限但真实

13 个来源注册在册，每个都有信任等级、采集状态和失败原因。不假装全网都爬过。

02 • 证据

每个字段留原文出处

每个字段单独一条证据：值、来源 URL 、提取方式、核验状态。原文网页全部留存。

03 • 核验

规则加人工兜底

只有官方来源且提取完全确定才自动标记已核验，其余全部进入人工审核队列。

方案

证据模型：把一句话拆成可复查的字段

活动名、日期、场馆、组织方，每个字段独立记录，独立核验，独立失败。

字段	值	来源	提取方式	状态
活动名	苏州交响乐团音乐会	场馆官网	结构化	已核验
开始日期	2027-01-08	场馆官网	结构化	已核验
场馆	苏州交响乐团音乐厅	场馆官网	结构化	已核验
组织方	来源未给出该字段	—	—	缺失
商圈	湖东	高德反查	推断	待复核

缺失和待复核都被明确记录，而不是留空。留空看起来像没有这个字段，记录状态才知道是来源本来就没给。

方案

自动核验只有一条规则，而且很窄

自动标记已核验

官方来源（政府 / 场馆官网）
并且 提取完全确定
两个条件同时成立才算

进入人工审核队列

聚合平台 / 社区帖
或者 日期靠推断、场馆靠猜
命中任意一条就不自动核验

- **不做看起来对就放过**
  宁可显示待复核，也不给一个无法追溯的已核验。

- **实际分布**
  1376 条字段证据中，已核验 335 条（24%），待复核 612 条（44%），缺失 294 条（21%）。

方案

人工审核是主角，不是补丁

- **一个字段一个决定**
  通过 / 驳回 / 修正 / 确认来源确实没有这个值，四种决定分开记录。
- **必须署名**
  每条决定记录审核人姓名和时间。没有署名的核验等于没有核验。
- **决定会持久保留，也会失效**
  重新采集不会覆盖人工判断；但来源的值变了，人工决定自动失效，避免用旧判断背书新数据。
- **一次核完一个活动**
  「全部核查完毕」提交后，明确报告还剩几个冲突字段需要单独处理。

目前已记录 97 条人工决定。入口在「证据与数据质量」页面，每条证据都能点开看到原始网页。

产品

六个页面，覆盖从发现到核验的完整链路

城市活动地图

按类别着色，热点场馆带脉冲光环

活动日历

月视图，一眼看出活动密度高峰

知识图谱

活动到场馆到商圈到酒店的关联

酒店活动情报

15 家酒店按地段分三档，标注周边活动

商圈洞察

哪些区域在发热，酒店供给对比

证据与数据质量

逐字段核验入口、来源状态、前端错误

也做了手机适配：导航移到底部，地图高度随屏幕自适应，宽表格可横向滑动。

成果

当前真实数据（不是演示数据）

134 活动	51 场馆	15 酒店	1376 字段证据
1848 原始网页留存	116 可地图绘制	80 未来活动	97 人工决定

全部来自 13 个注册来源的真实采集，数据库里 0 条 MOCK 数据。

覆盖 29 个商圈 / 街道，活动日期跨度 2025-05 到 2027-07 。

技术

工程实现

采集
Python 适配器，遵守 robots.txt
限速重试，失败记录原因，绝不制造活动

部署
阿里云 + Nginx + systemd
每日定时采集，已上线运行

后端
FastAPI + SQLite
每个字段的证据独立存储与查询

质量
后端 445 个测试，前端 66 个测试
全部通过

前端
React + TypeScript + Vite + antd
六页界面，高德地图

AI 辅助
DeepSeek 读原始页面交叉核对提取结果
AI 只做读者，不做权威

诚实

已知局限（不回避）

这些限制在系统里都是可见状态，不是藏起来的问题。

- **4 个来源当前采集失败**
  政府 SIPAC 页面无可提取事件；苏州文化艺术中心是 JS 空壳；大麦搜索页被 robots.txt 禁止； Subao 抽不出有效日期。原因逐条记录在系统里。

- **18 个场馆还没有坐标**
  多为小剧场、茶馆、 livehouse ，高德没有对应条目，需要人工指定。

- **活动级已核验目前是 0**
  一个活动要全部事实字段都核验才算通过，人工审核还没做完。字段级已核验为 335 条。

- **不做收益预测，也不对接 RMS**
  项目边界：只提供外部需求信号，不预测收入，不自动调价。

计划

下一步

扩大来源覆盖

把失败来源换成可用替代（场馆公众号、票务官方页），并接入更多政府与场馆来源。

补齐场馆坐标

剩余 18 个场馆人工指定坐标，把可绘制活动从 116 条提到接近全覆盖。

完成一轮人工审核

让活动级已核验真正可用，并量化人工审核的真实工作量。

域名与 HTTPS

接入正式域名，让钉钉和微信里可以直接打开，不带安全警告。

现在就能打开

系统已上线运行

扫码或直接在浏览器输入地址，看到的是真实数据库和真实采集结果。

http://47.116.133.230

建议按这个顺序看：

① 城市活动地图 —— 类别分色与热点场馆

② 酒店活动情报 —— 酒店分层与周边活动

③ 证据与数据质量 —— 点开任意一条看原始来源

扫码打开

手机浏览器打开，首次可能提示非 HTTPS

总结

一句话总结

我们做的不是爬虫，而是一条让每个数字都能被追问的数据链。

- **可追溯**
  每个字段都能点开，看到它来自哪个网页的哪一段。
- **不编造**
  缺失就标缺失，不确定就标待复核，绝不静默补全。
- **可交付**
  系统已上线，有地址有二维码，现在就能打开验证。